Analyse et modélisation statistique multi-échelle de séries chronologiques financières

Master 2 - Probabilités et Finance

Microstructure noise, realized volatility, and optimal sampling

---

Salma ZRIAA

Professeur: Emmanuel Bacry

Avril 2026

Contents

1 Résumé de l'article **2**
1.1 Introduction . . . 2
1.2 Set-up de l'estimation . . . 2
1.3 MSE conditionnel . . . 3
1.4 Sampling optimal . . . 4
1.4.1 Estimation de la fréquence optimale du sampling . . . 5
1.5 Simulations . . . 5
1.6 Une application empirique . . . 9
1.7 Conclusion . . . 10

2 Modèle à zones d'incertitude **11**
2.1 Introduction & Cadre de travail . . . 11
2.2 Estimation de la variable η . . . 12
2.3 Estimation de la volatilité réalisée & la corrélation . . . 13
2.4 Estimateur Hayashi-Yoshida . . . 14

1 Résumé de l'article

1.1 Introduction

En basse fréquence, comme le logarithme du prix est modélisé par une semi-martingale, il est possible d'estimer sa volatilité intégrée à partir la somme des carrés des accroissements du log prix sur des intervalles de très petites largeurs. Cette procédure est justifiée par la convergence en probabilité des rendements logarithmiques vers la variation quadratique du log prix. Cependant, en haute fréquence, la validité empirique de cette estimation requiert l'observabilité et la connaissance exacte du processus du prix réel. En réalité, les prix traités sur le marché diffèrent des prix "efficients", ce sont des données bruitées par **l'effet de microstructure** en HF (effet du bid-ask spread, signature plot non plats divergeant en HF, prix constants par morceaux...). En effet, Ce bruit de miscrostructure est d'autant plus important que la fréquence d'échantillonnage est élévée. Ceci implique que le modèle de semi-martingale pour le prix n'est plus adapté et donc l'estimateur **model-free** de la volatilité réalisée n'est plus un estimateur consistant (comme l'erreur de la variance réalisée n'est plus négligeable). Par conséquent, il est nécessaire de déterminer la fréquence optimale en réalisant un compromis entre une bonne précision de l'estimation et une meilleure gestion du bruit de microstructure.

Selon Barndorff-Nielsen and Shephard (BS), réaliser des inférences avec des données de très haute fréquence ou échantillonner des données massives avec une fréquence élévée peut être dangereux, car l'erreur sur la volatilité réalisée n'est plus négligeable en haute fréquence. Pour Anderson et al, il est impossible d'échantillonner asymptotiquement un nombre infini de petits accroissements de prix observés sur une courte période, car l'effet de la microstructure peut créer une distorsion dans les propriétés intraday observées. En d'autres termes, la microstructure du marché peut altérer la façon dont les prix se comportent à très haute fréquence, ce qui peut rendre difficile l'obtention d'un échantillon représentatif des propriétés du marché. Finalement, Bandi et Russell ont rigoureusement démontré que l'estimation de la volatilité réalisée par la variation quadratique n'est plus fiable lorsque le nombre d'observations augmente. En effet, cette méthode d'estimation diverge presque certainement lorsque le nombre d'observations tend vers l'infini sur une période fixe.

Dans la suite de ce rapport, on présentera les différents objectifs de l'article [1] qui sont axés sur la modélisation du bruit de microstructure, l'évaluation de l'impact de ce bruit sur les estimateurs et la mesure de la MSE conditionnel avec l'utilisation de l'estimateur model free de le volatilité. Finalement, une procédure de minimisation de la MSE mène à définir un choix optimal de la fréquence d'échantillonnage définissant un compromis entre la précision de l'estimateur et l'erreur induite par le bruit de microstructure.

1.2 Set-up de l'estimation

On modélise le prix sur une durée prédéterminée notée h, correspondant en général à une journée de trading. On suppose que le prix obéservé sur le marché vaut le vrai prix (exacte) multiplié par un facteur qui tent en compte l'effet de microstructure $\tilde{p}_{ih} = p_{ih}\bar{\eta}_{ih}$.
Ainsi les log incréments du prix observées diffèrent de ceux du vrai prix, du fait de l'existence d'un bruit additif que l'on notera epsilon

$$\underbrace{\ln\left(\tilde{p}_{ih}\right) - \ln\left(\tilde{p}_{(i-1)h}\right)}_{\tilde{r}_i} = \underbrace{\ln\left(p_{ih}\right) - \ln\left(p_{(i-1)h}\right)}_{r_i} + \underbrace{\eta_{ih} - \eta_{(i-1)_h}}_{\varepsilon_i} \quad i = 1, 2, \ldots, n$$

avec $\eta = \ln(\bar{\eta})$.

Dans le cadre du travail de l'article, l'auteur propose de faire les hypothèses suivantes sur la dynamique des prix et sa volatilité :

- Le log de prix est une semi-martingale continue.
- Le processus de la volatilité spot σ_t est càdlàg, bornée loin de zéro.
- Le mouvement brownian qui pilote la dynamique du log de prix et la volatilité spot sont indépendants.

Pour chaque jour (indexé par "i" dans la formule ci-dessus), il est supposé que la période d'intérêt "h" est divisée en "M" sous-périodes, permettant ainsi de définir les log-rendements intraday des données à haute fréquence échantillonnées à une fréquence de M/h.

$$\tilde{r}_{j,i} = \ln\left(\tilde{p}_{(i-1)h+j\delta}\right) - \ln\left(\tilde{p}_{(i-1)h+(j-1)\delta}\right) \quad j = 1, 2, \ldots, M$$

Ainsi, on obtient $\tilde{r}_{j,i} = r_{j,i} + \varepsilon_{j,i}$ avec $\varepsilon_{j,i} = \eta_{(i-1)h+j\delta} - \eta_{(i-1)h+(j-1)\delta}$.

On suppose également que :

- Les composantes du bruit microstructure sont des i.i.d avec un moment d'ordre 4 borné.
- La dynamique du log-prix est de drift nul, ce qui implique que la moyenne des rendements logarithmiques est nulle et que leur variance est égale à : $\int_{(i-1)h+(j-1)\delta}^{(i-1)h+j\delta} \sigma_s^2 ds$
- Les bruits additifs et les variations logarithmiques de rendement ("log-return") sont indépendants pour une même période et une même journée.

En prenant en compte toutes ces suppositions, nous établissons l'estimateur de la volatilité réalisée au jour i comme étant la variation quadratique du log prix réalisée au i-ème jour:

$$\hat{V}_i = \sum_{j=1}^{h/\delta} \tilde{r}_{j,i}^2$$

$\hat{V}_i$ est considéré en basse fréquence comme un estimateur de la quantité $\int_{(i-1)h}^{(i-1)h} \sigma_s^2 ds$.

L'objectif est donc de déterminer à quelle fréquence cet estimateur converge et de quantifier l'erreur d'estimation dans le cas où une telle convergence est observée. À cet effet, on considère la **MSE** (erreur quadratique moyenne):

$$\mathbf{E}_\sigma\left(\widehat{V}_i - V_i\right)^2 = \mathbf{E}_\sigma\left(\sum_{j=1}^{h/\delta} \tilde{r}_{j,i}^2 - \int_{(i-1)h}^{ih} \sigma_s^2 ds\right)^2$$

Dans ce qui suit on montre que la MSE diverge quand la fréquence d'échantillonnage augmente indéfiniment et qu'elle atteint son minimum pour un nombre fini d'observations M^*.

1.3 MSE conditionnel

Dans notre contexte de travail et sous les hypothèses mentionnées précédemmment, la MSE peut etre decomposée en deux parties distinctes. La première partie converge presque certainement vers

zéro lorsque la fréquence d'échantillonnage tend vers l'infini, tandis que la seconde partie prend en compte la distorsion créée par le bruit de microstructure et diverge à haute fréquence.

$$\mathbf{E}_\sigma\left(\widehat{V}_i - \int (i-1)h^{ih}\sigma_s^2 ds\right)^2 = 2\frac{h}{M}\left(V_i^2 + o_{a\cdot s.}(1)\right) + M\beta + M^2\alpha + \gamma$$

Les termes en α, β et γ prennent en considération le bruit de microstructure à travers ses moments et la corrélation de sa structure.

$$\begin{aligned}
\alpha &= \left(\mathbf{E}_\sigma\left(\varepsilon^2\right)\right)^2 \\
\beta &= \mathbf{E}_\sigma\left(\varepsilon^4\right) + 2\mathbf{E}\sigma\left(\varepsilon^2\varepsilon_{-1}^2\right) - 3\left(\mathbf{E}_\sigma\left(\varepsilon^2\right)\right)^2 \\
\gamma &= 4\mathbf{E}_\sigma\left(\varepsilon^2\right)V_i - 2\mathbf{E}_g\left(\varepsilon^2\varepsilon{-1}^2\right) + 2\left(\mathbf{E}_\sigma\left(\varepsilon^2\right)\right)^2
\end{aligned}$$

Il parait donc clair que la somme des carrés de rendements contaminés par l'effet de microstructure induit à la fois un terme de variance supplémentaire et un terme de biais $\mathbf{E}_\sigma(\hat{V}_i - V_i)$ qui ont le potentiel d'affecter considérablement la décomposition MSE conditionnelle.

De ce fait, Il est évident que la présence de bruit de microstructure conduit à une divergence du MSE lorsque le nombre de points augmente indéfiniment en raison de la variance supplémentaire. Cette variance supplémentaire ne place aucune contrainte sur la distribution ou la nature du bruit de microstructure. En ce qui concerne le bruit de microstructure, la variance supplémentaire ne place aucune contrainte sur la distribution ou la nature de ce dernier.

1.4 Sampling optimal

Étant donné la formule pour quantifier le MSE et le fait que le MSE diverge pour des valeurs de M très élevées, il est important de choisir une valeur optimale de M afin de minimiser l'erreur quadratique de l'estimation. Par conséquent, nous cherchons la valeur de M qui satisfait cette condition:

$$\left\{M^* := argmin\left(2\frac{h}{M}\left(V_i^2 + o_{a\cdot s.}(1)\right) + M\beta + M^2\alpha + \gamma\right)\right\}$$

De façon équivalente:

$$\left\{M^* := 2M^3\alpha + M^2\beta - 2h\left(V_i^2 + o_{a\cdot s.}(1)\right) = 0\right\}$$

avec les termes α, β et γ définis ci-dessous.

Une méthode pratique couramment utilisée pour les applications est de prendre M^* dans sa forme empirique comme suit:

$$M^* = \left(\frac{hV_i^2}{\left(\mathbf{E}_\sigma\left(\varepsilon^2\right)\right)^2}\right)^{1/3}$$

avec $V_i^2 = \int_{(i-1)h}^{ih}\sigma_s^4 ds$ est est la variance quartique réalisée au i-ème jour, appelée aussi 'quarticity' dans la suite. $\mathbf{E}_\sigma\left(\varepsilon^2\right)$ est le deuxième moment des contaminations (bruit) dans les rendements.
Si le terme quadratique l'emporte sur le terme linéaire (pour des valeurs de M suffisamment grandes), l'approximation M^* donne une représentation très précise du nombre optimal d'observations M.

A partir de cette règle empirique pratique, il parait clair que la "quarticity" du prix logarithmique et le carré de la variance du bruit de microstructure sont les facteurs qui permettent de déterminer la fréquence d'échantillonnage optimale. Si le rapport entre le carré de la variance du bruit et la "quarticity" est élevé, une fréquence d'échantillonnage plus basse est nécessaire pour minimiser la distorsion causée par la microstructure. Ce rapport peut être considéré comme un rapport signal sur bruit (SNR).

BR a trouvé des résultats similaires, démontrant que lorsque le rapport entre la variance du bruit et la variance quadratique est élevé, cela introduit un biais dans l'estimation, ce qui nécessite moins de points d'échantillonnage (donc une fréquence plus faible) pour effectuer l'estimation avec précision.

1.4.1 Estimation de la fréquence optimale du sampling

En présence des estimateurs consistents pour les grandeurs α et β, la formule précédente pour un M optimal: $\left\{M^* := 2M^3\alpha + M^2\beta - 2h\left(V_i^2 + o_{a\cdot s.}(1)\right) = 0\right\}$ peut-etre résolue numériquement.

La nature de notre problème rend l'estimation de V_i^2 difficile car il n'est pas possible de passer par un estimateur qui ne tient pas compte du bruit de la microstructure. Néanmoins, les simulations ont démontré que l'utilisation d'estimateurs différents n'a pas un impact significatif sur la fréquence d'échantillonnage optimale. En plus, il a été prouvé qu'en disponibilité des données en haute fréquence, on peut obtenir des estimateurs consistants pour alpha et beta en exploitant les deux résultats suivants:

- L'estimateur standard de la volatilité réalisée converge en probabilité vers le moment d'ordre 2 du bruit non observable.
- Sous les hypothèses initiales mentionnées précédemment sur le processus log-prix et les log-rendements, on a :

$$\frac{1}{M}\sum_{j=1}^{h/\delta}\widetilde{r}_{j,i}^4 \xrightarrow{p} \mathbf{E}_\sigma\left(\varepsilon^4\right).$$

En utilisant l'hypothèse d'indépendance entre les epsilons, il en résulte que $= \mathbf{E}_\sigma\left(\varepsilon^2\varepsilon_{-1}^2\right) = 2\mathbf{E}_\sigma\left(\varepsilon^4\right)$ ce qui rend possible l'estimation de tous les paramètres inconnus et donc la détermination de la fréquence d'échantillonnage optimale des données HF.

Une extension envisageable consisterait à rechercher la fréquence optimale qui permet de minimiser le MSE moyen sur l'ensemble des jours, plutôt que sur un jour i spécifique. Cela équivalent à remplacer V_i^2, qui est calculée sur i uniquement, par $\frac{1}{n}\sum_{i=1}^n V_i^2$ qui est une moyenne portant sur l'ensemble des jours.

1.5 Simulations

L'objectif principal de cette section est d'évaluer la précision de la théorie du cadre de notre travail.

Dans un premier temps, nous vérifierons que si la fréquence d'échantillonnage est plus élevée, l'estimateur du moment d'ordre 4 du bruit de microstructure devient de plus en plus consistent. Ainsi, en combinant cet estimateur avec l'estimateur du moment d'ordre 2 du bruit de microstructure, tous les termes du problème de minimisation de l'erreur quadratique moyenne (MSE) peuvent être identifiés, à l'exception du terme V_i^2. Ensuite, nous montrons ensuite que l'estimateur de V_i^2 n'a en fait que peu d'impact sur la fréquence optimale d'échantillonnage des données à haute fréquence pour estimer la volatilité réalisée par le processus log-prix. Un résultat préliminaire attendu est un seuil de coupure

de 15 minutes entre la haute fréquence et la basse fréquence.
Enfin, nous montrons que si V_i^2 est correctement estimé avec une bonne précision, alors la règle empirique donnant $M^* = \left(\frac{hV_i^2}{(\mathbf{E}_\sigma(\varepsilon^2))^2}\right)^{1/3}$ produit une distribution de fréquence optimale similaire à celle obtenue en résolvant le problème de minimisation complet.

On considère la dynamique du log-prix à volatilité stochastique:

$$d\log(p)_t = \sigma_t dW_t^1$$
$$d\sigma_t^2 = \kappa\left(\bar{v} - \sigma_t^2\right)dt + \varpi\sigma_t dW_t^2$$

avec $\kappa = 0.01$ $\bar{v} = 1$ $\varpi = 0.05$.

Il est supposé par la suite que les log-bruits suivent une distribution gaussienne avec une moyenne de zéro et un écart-type de 0,000197. Cette hypothèse implique que le rapport entre la variance des epsilons (les log-rendements des chocs ou des bruits) et la variance quotidienne est de 0,02829 %. En conséquence, les simulations peuvent représenter une situation d'actions liquides telles qu'IBM. La relation entre le rapport et la liquidité de l'action est discutée dans l'article BR(2003a).

Nous effectuons une simulation en générant 1 000 séries de rendements contaminées 1 000 séries de rendements contaminées pour une période de 6,5 heures et une seule valeur de volatilité réalisée. Pour ce faire, nous utilisons la dynamique de la volatilité stochastique pour simuler une trajectoire de la volatilité seconde par seconde, à partir d'une valeur initiale de 1. Ensuite, nous fixons la trajectoire de la volatilité et utilisons la dynamique du processus log-prix pour simuler les log-rendements du prix seconde par seconde. Enfin, nous simulons les log-rendements observés en utilisant l'hypothèse selon laquelle la distribution des log-bruits suit une loi normale.

Les graphiques présentés ci-dessus comparent les log-rendements observés avec les vrais log-rendements pour deux fréquences d'échantillonnage différentes (toutes les 15 minutes à droite et toutes les secondes à gauche). Il est clairement évident que les données seconde par seconde sont très perturbées par le bruit de la microstructure, alors que ce n'est pas le cas pour les données échantillonnées toutes les 15 minutes. Ce résultat avait été énoncé précédemment et il est également confirmé par les simulations.

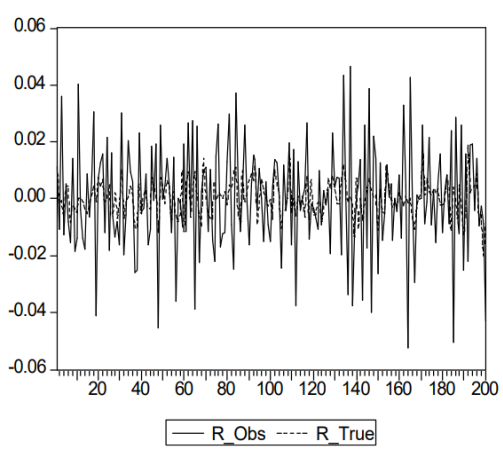

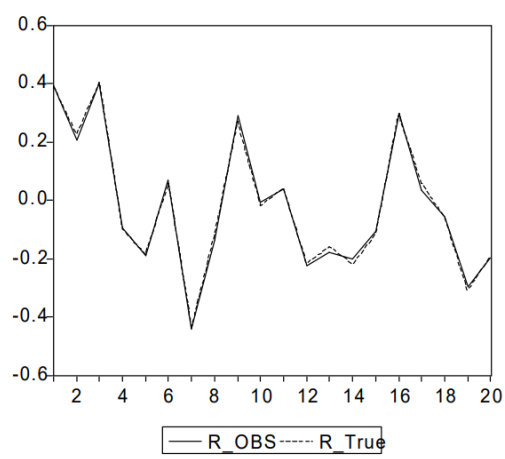

La figure présentée ci-dessous illustre la convergence de la moyenne empirique du moment d'ordre 4 des log-returns de bruits pour 2 fréquences d'échantillonnage. Les graphiques reflètent la tendance attendue : à mesure que la fréquence augmente, la moyenne empirique du moment d'ordre 4 des log-returns bruités converge vers le moment d'ordre 4 du processus de bruit. De plus, la volatilité réalisée

normalisée converge vers le moment d'ordre 2 du processus de bruit.

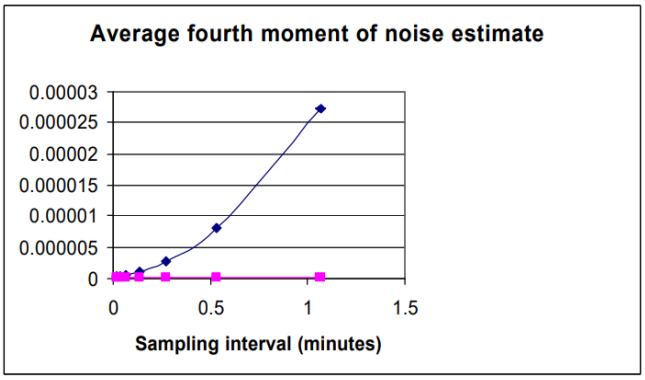

Ensuite, La figure suivante illustre la relation entre le MSE de l'estimateur de l'intégrale de la volatilité à la puissance 4 (quarticity) et la fréquence d'échantillonnage des données HF. Les résultats montrent que l'erreur quadratique minimale est atteinte pour une fréquence d'échantillonnage d'environ 2 minutes, tandis qu'elle est quatre fois plus grande pour un échantillonnage de 15 minutes, correspondant à la valeur empirique définie comme le seuil entre haute fréquence et basse fréquence. Cependant, même si cette fréquence est suboptimale pour estimer la volatilité réalisée à partir de données HF, elle reste assez conservatrice pour les actions liquides comme IBM.

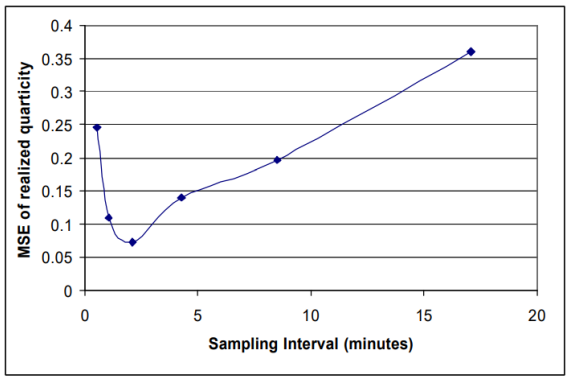

Ce qui suit présente des graphiques illustrant la répartition des fréquences optimales dans différentes configurations, basés sur 1000 simulations.

Tout d'abord, on calcule les fréquences à partir de la formule suivante:

$$M^* := argmin\left(2\frac{h}{M}\left(V_i^2 + o_{a\cdot s.}(1)\right) + M\beta + M^2\alpha + \gamma\right)$$

Cette formule inclut une estimation du terme « quarticity » obtenue dans un premier temps par échantillonnage toutes les 2 minutes. Bien que la vraie valeur de la fréquence optimale soit de 1,7 minute, il y a un biais dans la valeur moyenne et médiane. Cependant, l'histogramme des fréquences fournit des informations utiles sur l'ordre de grandeur de la fréquence optimale, car il permet de se maintenir à une distance raisonnable des basses fréquences qui conduisent à une grande valeur du MSE.

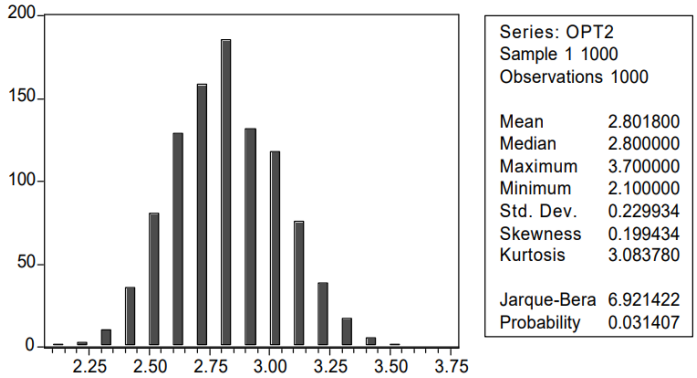

Toutefois, en ce qui concerne la figure ci-dessous, la configure générale similaire, à l'exception du fait que le terme "quarticity" est estimé toutes les 15 minutes par échantillonnage.
À cette fréquence, l'estimateur de V_i^2 présente une variance plus élevée, ce qui se traduit par un intervalle de valeurs de fréquences acceptables plus large que dans le cas précédent. Malgré cela, ces valeurs restent informatives.

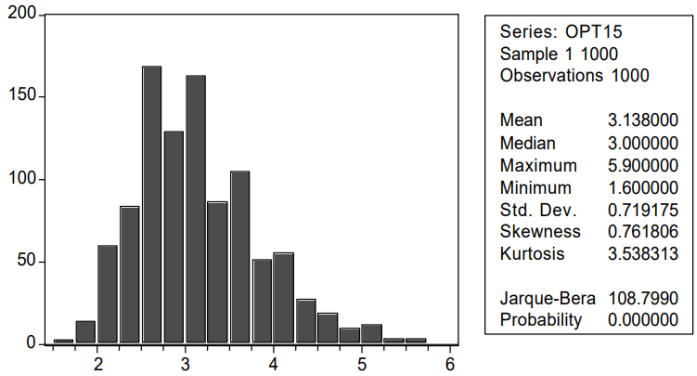

Les résultats de ces deux graphes illustrent finalement la conclusion qui avait été préalablement annoncée : « Bien qu'un estimateur de 15 minutes introduise davantage de variance dans l'estimation de la quarticité, cela n'a pas un impact significatif sur l'estimation de la volatilité réalisée à cette fréquence ». Par conséquent, un intervalle de 15 minutes peut être considéré comme une bonne fréquence sub-optimale pour estimer la volatilité réalisée, peu importe la liquidité des actions.

Dans un second temps, on utilise une deuxième méthode pour déterminer les fréquences optimales, en se basant sur la règle empirique au lieu de minimiser la formule précédente:

$$M^* = \left(\frac{hV_i^2}{\left(\mathbf{E}_\sigma\left(\varepsilon^2\right)\right)^2} \right)^{1/3}$$

Les figures ci-dessous présentent la répartition des fréquences optimales, en fonction l'estimateur de la quarticity obtenue par échantillonnage toutes les 2 minutes (à gauche) ou toutes les 15 minutes (à droite).

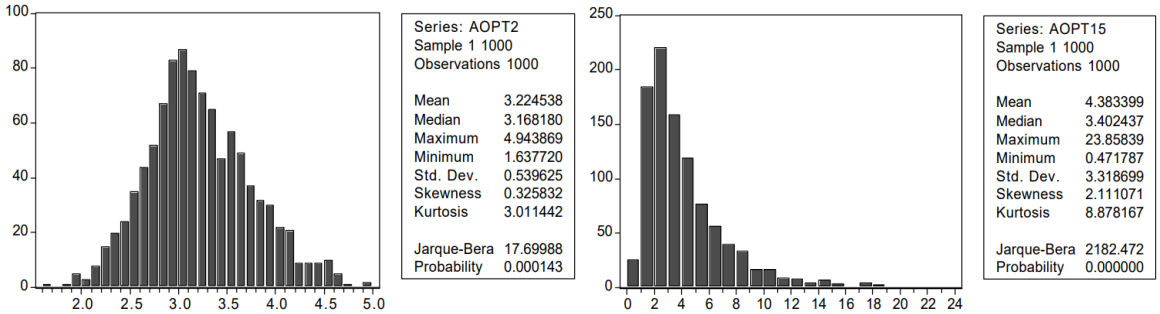

Il est clair que dans le cas de la méthode de la régle empirique, les estimateurs sont davantage biaisés en faveur de grandes valeurs et présentent une plus grande variance par rapport aux histogrammes obtenus dans la configuration précédente similaire. Cela est particulièrement vrai pour l'histogramme obtenu à partir d'échantillons prélevés toutes les 15 minutes. Par conséquent, il est préférable d'utiliser la règle empirique pour estimer la fréquence optimale lorsque la fréquence à laquelle on estime la quarticité est proche de la fréquence optimale recherchée pour estimer la volatilité réalisée. Cependant, l'intervalle de valeurs obtenu à partir de cet histogramme reste informatif quant à l'ordre de grandeur de la fréquence optimale.

1.6 Une application empirique

L'application étudie trois actions de liquidités différentes, à savoir IBM, Alcoa et Airgas, classées du plus liquide au moins liquide. Plus un actif est liquide, moins important est le rapport entre le moment d'ordre 2 du bruit et la volatilité réalisée par jour, en moyenne. Pour IBM, Alcoa et Airgas, ce ratio est égale à 0.283%, 0.742% et 0.217% respectivement.

Les figures suivantes présentent, pour une "quarticity" estimée par échantillonnage toutes les 15 minutes (comme précédemment établi), l'estimation du MSE et de la fréquence optimale par les deux méthodes (minimisation et règle empirique), pour IBM (figure de gauche), Alcoa (figure de droite) et finalement Airgas (figure en bas).

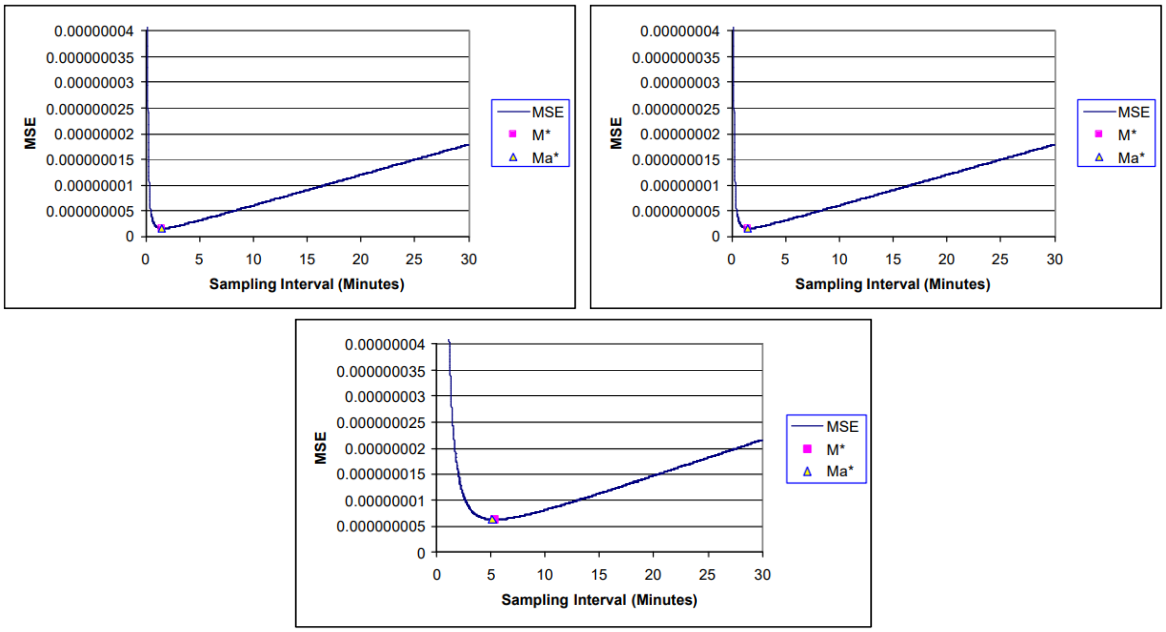

Il est évident que la fréquence d'échantillonnage optimale dépend de la liquidité de l'action. En effet, moins l'action est liquide, plus la période d'échantillonnage doit être grande. Dans notre cas, le minimun est atteint pour 1.5 minutes pour IBM, 2.9 minutes pour Alcoa et 5.3 minutes pour Airgas. De plus, l'utilisation d'une fréquence d'échantillonnage de 15 minutes entraîne une erreur d'estimation qui dépend elle-même de la liquidité de l'action en question.

Une dernière remarque concerne les résultats obtenus grâce à l'utilisation de la règle empirique. Cette méthode permet d'obtenir une bonne estimation de la fréquence optimale, qui n'est pas très éloignée de celle obtenue par la résolution du problème de la minimisation, et ce, quel que soit le niveau de liquidité de l'action. De plus, elle est moins coûteuse en termes de temps et de ressources.

1.7 Conclusion

À haute fréquence, le bruit de microstructure perturbe les prix efficients, entraînant ainsi un écart entre les prix observés et les prix efficients. Lors de l'estimation de la volatilité réalisée en haute fréquence, l'effet de microstructure introduit une erreur significative dans l'estimation model-free. Pour déterminer la fréquence optimale d'échantillonnage des données HF qui permette d'atteindre un compromis entre la précision et l'erreur de bruit de microstructure, il est nécessaire de résoudre un problème de minimisation de l'erreur quadratique moyenne conditionnelle (MSE), qui dépend de la structure du bruit de microstructure (autocorrélation, moments de différents ordres, etc.) qui peuvent être estimés à partir des données de marché observées, ainsi que de la volatilité quarticity qui est estimée sans tenir compte de l'impact de la fréquence d'échantillonnage sur l'estimation. Actuellement, il est courant d'utiliser une fréquence d'échantillonnage de 15 minutes, indépendamment de la liquidité de l'action concernée. Cependant, une règle empirique a été établie pour estimer rapidement la fréquence optimale, qui s'avère dépendente de la liquidité de l'action. Plus précisément, cette fréquence optimale est d'autant plus importante si l'action est moins liquide.

2 Modèle à zones d'incertitude

Le principal inconvénient de l'estimateur model free est qu'il suppose que les prix observés suivent une trajectoire semi-martingale continue. Cependant, en cas de transactions à haute fréquence, cette hypothèse n'est plus valide car les prix ne suivent plus un processus d'Itô. De plus, la notion de volatilité n'a plus de sens dans le contexte des prix observés.

Heureusement, le modèle à zones d'incertitude permet de reconstruire le prix efficient, qui suit un processus de diffusion et pour lequel l'estimateur sans modèle converge vers la volatilité réalisée intégrée. Ainsi, cette méthode offre une alternative pour estimer la volatilité future des actifs financiers, même en présence de données à haute fréquence.

2.1 Introduction & Cadre de travail

Le modèle comportant des zones d'incertitudes permet d'établir une relation entre le prix observé sur le marché et le prix efficient, qui est en réalité une semi-martingale continue. Cette relation est affectée par la présence de bruit de microstructure, qui provoque un décalage entre le prix observé et le prix efficient. Les prix évoluent lorsque les agents du marché estiment que le prix efficace a suffisamment changé et s'éloigne du "dernier prix négocié". Cette aversion au changement de prix est quantifiée dans le modèle par le paramètre η. Il peut etre interprété comme le paramètre qui capture la dynamique haute fréquence. On va montrer que l'avantage de ce modèle à zones d'incertitude est qu'avec un seul paramètre η on peut reproduire l'ensemble de la dynamique du prix efficient.

Pour notre cadre de travail, on note :

- X_t: prix efficient
- α: tick size
- P_{ti}: prix de la i-ème transaction

Lorsque les participants du marché estiment que le prix a considérablement changé, cela entraîne un saut dans le prix $L_i = |P_{t_{i+1}} - P_{t_i}|/\alpha$ dont la magnitude est déterminée par une variable aléatoire explicative χ_t. L'incertitude dans les fluctuations de prix est définie par deux paramètres,α et η , qui déterminent la zone d'incertitude par:

$$U_k = [0, \infty) \times (d_k, u_k)$$

où $d_k = (k + 1/2 - \eta)\alpha$ et $u_k = (k + 1/2 + \eta)\alpha$

Lorsque le prix entre dans cette zone d'incertitude, une valeur aléatoire χ_t est générée pour déterminer la taille du prochain saut de prix. Cela détermine également la zone dans laquelle nous sommes intéressés. Si le prix efficient atteint la limite supérieure (ou inférieure) de cette zone, le prix observé sur le marché augmentera (ou diminuera) de k ticksize, où k est la valeur de χ_t générée.

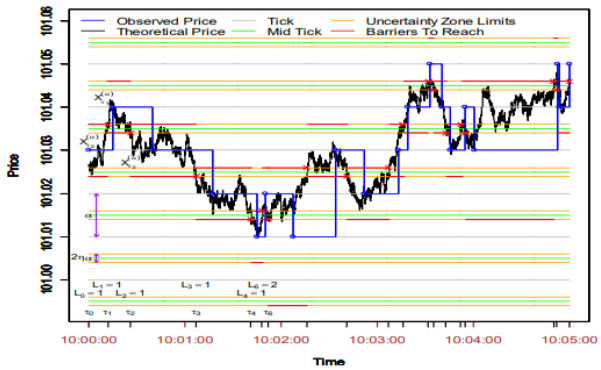

Ce modèle ne dispose que d'un seul paramètre, à savoir la largeur de la zone d'incertitude $2\eta\alpha$. Toutefois, étant donné que le ticksize est fixé par le régulateur, le seul paramètre effectif du modèle est l'aversion au changement de prix, représentée par η. Lorsque η est égal à 1/2, cela signifie que la zone d'incertitude coïncide avec les prix cotés, ce qui conduit à un effet de microstructure plus marqué en raison des fluctuations potentiellement plus importantes des prix.
Ainsi, il est possible d'établir une relation entre le prix efficient et le prix observé en utilisant la formule suivante :

$$X_{\tau i} = P_{ti} - \alpha(\frac{1}{2} - \eta)sign(P_{t_i} - P_{ti-1})$$

avec t_i: l'instant d'observation, τ_i: le temps de sortie de la zone d'incertitude.

En estimant la valeur de η, il devient alors possible de reconstituer le prix efficient, qui suit une trajectoire de semi-martingale, à partir des prix observés, qui sont constants par morceaux.
Il convient de noter que τ_i est défini par récurrence et représenté par $\tau_{i+}1 = \inf\{t > \tau_i, X_t = X_{\tau_i}^{(\alpha)} \mp \alpha(L_i - \frac{1}{2} + \eta)\}$ et déterminé en arrondissant la valeur de $X_{\tau i}$ au plus proche multiple de α, noté $X_{\tau_i}^{(\alpha)}$.

2.2 Estimation de la variable η

Les prix des transactions sont utilisés pour estimer l'aversion au changement de prix sur le marché noté η. Nous définissons une *continuation* comme une variation de prix dans le même sens que la variation précédente, et une *alternation* lorsque la variation est dans le sens opposé. Cette définition peut être étendue au cas de deux trades décalées de k trades. On définit donc:

$$N_{\alpha,t,k}^{(c)} = \sum_{i=1}^{N_{\alpha,t}} \mathbb{1}_{\{|X_{\tau_i} - X_{\tau_{i-1}}| = \alpha k\}}$$

$$N_{\alpha,t,k}^{(a)} = \sum_{i=1}^{N_{\alpha,t}} \mathbb{1}_{\{|X_{\tau_i} - X_{\tau_{i-1}}| = \alpha(k-1+2\eta)\}}$$

avec $N_{\alpha,t}$ le nombre total de transactions disponibles.

En utilisant cette méthode, on obtient un estimateur de η comme suit:

$$\hat{\eta}_t = \sum k = 1^m \lambda_{\alpha,t,k} u_{\alpha,t,k}$$

avec $\lambda_{\alpha,t,k} = \frac{N_{\alpha,t,k}^{(a)} + N_{\alpha,t,k}^{(c)}}{\sum_{j=1}^{m}\left[N_{\alpha,t,j}^{(a)} + N_{\alpha,t,j}^{(c)}\right]}$ and $u_{\alpha,t,k} = \frac{1}{2}\left(k\left(\frac{N_{\alpha,t,k}^{(c)}}{N_{\alpha,t,k}^{(a)}} - 1\right) + 1\right)$

La figure ci-dessous présente une estimation de η qui a été effectuée pour les indices boursiers allemands "Bund" et "DAX" en octobre 2010. "Bund" est l'indice des obligations souveraines allemandes à 10 ans et "DAX" est l'indice des 30 plus grandes entreprises cotées à la Bourse de Francfort.

Day	η (Bund)	η (FDAX)	Day	η (Bund)	η (FDAX)
1 Oct.	0.18	0.41	18 Oct.	0.16	0.33
5 Oct.	0.15	0.37	19 Oct.	0.13	0.37
6 Oct.	0.15	0.37	20 Oct.	0.13	0.33
7 Oct.	0.15	0.38	21 Oct.	0.15	0.33
8 Oct.	0.15	0.41	22 Oct.	0.11	0.33
11 Oct.	0.14	0.36	25 Oct.	0.12	0.31
12 Oct.	0.14	0.36	26 Oct.	0.14	0.31
13 Oct.	0.14	0.32	27 Oct.	0.14	0.32
14 Oct.	0.16	0.35	28 Oct.	0.14	0.32
15 Oct.	0.16	0.35	29 Oct.	0.14	0.34

2.3 Estimation de la volatilité réalisée & la corrélation

Si on suppose que la dynamique du prix efficient s'écrit comme:

$$\mathrm{d}\log X_u = a_u du + \sigma_{u^-} dW_u$$

alors on définit:

$$\widehat{RV}_t = \sum_{i=1}^{N_{\alpha,t}} \left(\log\left(\hat{X}_{\tau_i}\right) - \log\left(\hat{X}_{\tau_{i-1}}\right)\right)^2$$

qui sera liée à la variation quadratique. Cette définition sera basée sur le résultat qui permet d'obtenir l'estimateur naturel de la volatilité intégrée réalisée par la relation suivante :

$$\alpha^{-1}\left(\widehat{RV}t - RV_t\right) \xrightarrow{\mathcal{L}_s} \gamma_t \int_0^t v_u \ \mathrm{d}W\theta_u$$

Il est important de noter que cette asymptote est atteinte lorsque le tick-size tend vers zéro.

L'impact de la microstructure ne se limite pas uniquement à altérer l'estimation de la volatilité intégrée réalisée, il affecte également l'estimation de la corrélation entre deux actifs.
On considère la dynamique du prix efficient pour deux assets:

$$\begin{aligned} \mathrm{d}\log X_t &= \mu_t^X \ \mathrm{d}t + \sigma_{t-}^X \ \mathrm{d}W_t, \\ \mathrm{d}\log Y_t &= \mu_t^Y \ \mathrm{d}t + \sigma_{t-}^Y \ \mathrm{d}B_t, \\ \mathrm{d}\langle W, B\rangle_t &= \rho_t \ \mathrm{d}t. \end{aligned}$$

La figure ci-dessous présentent les séries temporelles de prix de deux actifs "Bund and Bobl":

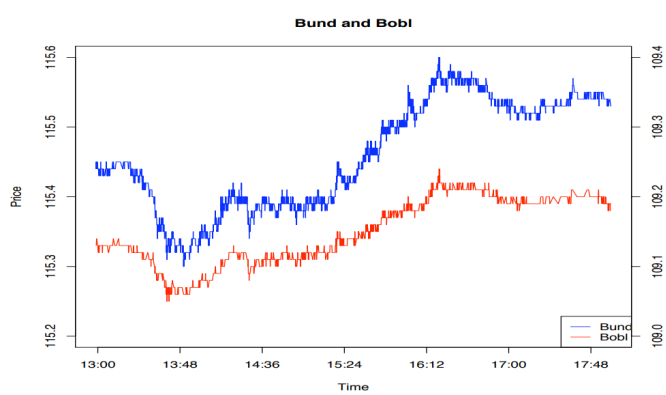

L'objectif est donc d'estimer la quantité suivante: $\int_0^1 \rho_t \sigma_t^X \sigma_t^Y \ \mathrm{d}t$.

Afin de réaliser cela, nous devrons affronter deux défis majeurs. Le premier lié à l'asynchronicité des données dans le temps, et le second lié aux effets de la microstructure sur les données. Dans un premier temps, on suppose que les données (X_i, Y_i) sont observés simultanément et sans effet de microstructure, alors on peut prendre comme estimateur de $\int_0^1 \rho_t \sigma_t^X \sigma_t^Y \ \mathrm{d}t$ la quantité:

$$\widehat{c_n} = \sum_{i=1}^{n} \Delta_i^n X \Delta_i^n Y$$

Cette estimateur est convergent avec une vitesse déterminée de $n^{1/2}$.
Dans le cas du marché financier, cet estimateur n'est plus consistent suite aux deux contraints mentionnées précédemment. Tout d'abord, les transactions sur les deux actifs ne sont pas simultanées. De plus, en raison de l'effet de microstructure, les modèles de semi-martingales continues ne sont pas valables.

Supposons maintenant que nous observions l'actif X à des moments $(T^{X,i})$, où $i = 1, ...$ et l'actif Y à des moments $(T^{Y,i})$, où $i = 1, ...$ On définit alors les deux processus définis par morceaux :

$$\bar{X}_t = X_{T^{X,i}} \text{ for } t \in \left[T^{X,i}, T^{X,i+1}\right)$$
$$\bar{Y}_t = Y_{T^{Y,i}} \text{ for } t \in \left[T^{Y,i}, T^{Y,i+1}\right).$$

pour un h donné, l'estimateur naturel est donc:

$$V_h = \sum_{i=1}^{m} \left(\log \bar{X}_{ih} - \log \bar{X}_{(i-1)h}\right) \left(\log \bar{Y}_{ih} - \log \bar{Y}_{(i-1)h}\right)$$

Cet estimateur présente un biais systématique qui conduit à une estimation de la corrélation entre X et Y très faible, voire nulle. En effet, $\mathbb{E}[V_h] \to 0$ quand $h \to 0$.
Ce biais est dû à la construction de l'estimateur sur un intervalle de largeur h, qui ne garantit pas que les valeurs de $\bar{X}$ et $\bar{Y}$changent de manière systématique, entraînant des incréments nuls. Ce phénomène est connu sous le nom d' **effet Epps**, voir figure ci-dessous.

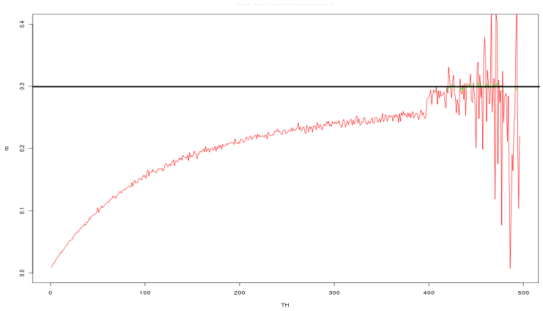

2.4 Estimateur Hayashi-Yoshida

Afin de pallier au problème d'asynchronicité, on définit un nouveau estimateur d'Hayashi-Yoshida est défini par :

$$U_n = \sum_{i,j} \Delta X\left(l_i^X\right) \Delta Y\left(l_j^Y\right) \mathbf{1}_{\left\{l_i^X \cap l_j^Y \neq \varnothing\right\}}$$

où les intervalles $I_i^X = \left(T^{X,i}, T^{X,i+1}\right]$ et $I_i^Y = \left(T^{Y,i}, T^{Y,i+1}\right]$ sont définis par les moments de trades respectifs sur X et Y.

Contrairement à d'autres estimateurs, Hayashi-Yoshida n'a pas besoin d'un choix de largeur d'intervalle h, néamoins il reste inadapté pour prendre en compte l'effet de microstructure. Par conséquent, il peut être combiné avec l'estimateur des prix efficients dans un modèle à zones d'incertitude pour traiter efficacement ce problème.

References

[1] Federico M. Bandi and Jeffrey R. Russell. *Microstructure noise, realized volatility, and optimal sampling*. Nov. 2003.